

Proyecto Final 4Geeks - FAOSTAT

Guía explicativa: que pide la entrega, como se realizó el proyecto y que debe presentarse.

1. Que debemos hacer

La entrega pide construir un proyecto completo de Machine Learning: definir un problema de negocio, obtener datos desde una fuente real, almacenarlos en una base de datos, analizarlos, entrenar un modelo optimizado y desplegarlo en una aplicación web.

Fase	Que se debe entregar
Paso 1	Definir un problema real y convertirlo en un problema de Machine Learning.
Paso 2	Obtener datos desde una API, portal, web scraping o base pública; guardarlos como CSV y cargarlos con Pandas.
Paso 3	Guardar la información en una base de datos y realizar consultas SQL como SELECT, JOIN e INSERT.
Paso 4	Realizar análisis descriptivo: medias, medianas, desviaciones, modas, nulos, distribuciones y, si aplica, hipótesis.
Paso 5	Hacer un EDA completo, seleccionar variables útiles y dividir los datos en train y test.
Paso 6	Entrenar, comparar u optimizar un modelo usando hiperparámetros y métricas de evaluación.
Paso 7	Crear una app web con el modelo guardado y dejarla lista para despliegue.

2. Problema elegido

El problema elegido fue estimar el valor esperado de bioenergía por país, año, ítem y tipo de medición. Esto sirve para apoyar decisiones sobre inversión, investigación y priorización de cadenas agroalimentarias con potencial energético.

El objetivo de Machine Learning es una regresión: predecir un valor numérico llamado `target_value`. Para mejorar el entrenamiento se usa también `log_target_value`, que reduce el efecto de valores extremos.

3. Datos utilizados

La fuente solicitada fue FAOSTAT, específicamente el dominio AF. Ese dominio corresponde a ASTI - Researchers. Como AF por sí solo no alcanza las 60.000 filas, se usó como fuente contextual y se combinó con otros dominios oficiales de FAOSTAT.

Código	Nombre	Uso en el proyecto
AF	ASTI - Researchers	Fuente pedida y variable de contexto sobre investigadores agrícolas.
AE	ASTI - Expenditures	Contexto de gasto en investigación agrícola.
CISP	Country Investment Statistics Profile	Contexto de inversión y valor agregado agropecuario.
BE	Bioenergy	Tabla principal para construir el modelo predictivo.

Los datos se descargan desde el catálogo bulk oficial de FAOSTAT, se guardan en `data/raw`, se transforman con Pandas y se exporta el dataset final a `data/processed/modeling_dataset.csv`.

4. Cumplimiento de requisitos minimos

Requisito	Resultado del proyecto	Estado
Minimo 60.000 filas	101,995 filas	Cumplido
Minimo 20 predictores	26 predictores	Cumplido
Al menos 1 categorica	7 categoricas	Cumplido
CSV final	data/processed/modeling_dataset.csv	Cumplido
Base de datos	data/database/faostat_project.db	Cumplido
Notebook ejecutado	notebooks/explore.ipynb con salidas guardadas	Cumplido

5. Como se realizo tecnicamente

Obtencion y carga

El script `src/data_download.py` descarga los ZIP oficiales de FAOSTAT. Luego lee los CSV internos con Pandas, normaliza los nombres de columnas y conserva el codigo de fuente de cada tabla.

Base de datos

El script `src/database.py` crea una base SQLite. Guarda las tablas `raw_af`, `raw_ae`, `raw_be`, `raw_cisp` y `modeling_bioenergy`. En el notebook se muestran consultas `SELECT`, `JOIN`, agregaciones e `INSERT`.

Feature engineering

El script `src/features.py` combina los dominios por pais y ano, crea variables de contexto y genera variables temporales como `target_lag_1`, `target_lag_2`, `target_lag_3` y `target_roll_mean_3`.

EDA y analisis descriptivo

El EDA calcula estadisticas descriptivas, nulos y distribuciones. El dataset final tiene una media del objetivo de 447,212.72, mediana de 11,815.20 y una tasa promedio de nulos de 19.26%. Tambien se agrego un contraste Kruskal-Wallis para revisar diferencias del objetivo por item.

Modelo

Se entreno un `HistGradientBoostingRegressor` porque puede capturar relaciones no lineales y funciona bien en datos tabulares. Se uso `GridSearchCV` para optimizar hiperparametros y una division temporal `train/test` para respetar el orden cronologico.

Metrica	Valor
Filas train	84,749
Filas test	17,246
MAE	60,528.02
RMSE	641,472.23
R2 sobre log-target	0.990
Mejores parametros	{'model__learning_rate': 0.08, 'model__max_iter': 140, 'model__max_leaf_nodes': 31}

6. Aplicacion web y despliegue

La app esta construida con Streamlit en `src/app.py`. Permite seleccionar pais, ano, item y tipo de medicion, y devuelve una prediccion usando el modelo guardado en `models/bioenergy_model.joblib`.

Para despliegue se dejo `render.yaml`, que instala dependencias, prepara el pipeline y ejecuta Streamlit en Render. Localmente se puede abrir con: `streamlit run src/app.py`

7. Que decir en la presentacion de 5 minutos

Tiempo	Mensaje recomendado
0:00 - 0:45	Problema: identificar potencial de bioenergia en sistemas agroalimentarios.
0:45 - 1:30	Datos: FAOSTAT, dominio AF solicitado y enriquecimiento con BE, AE y CISP.
1:30 - 2:30	Patrones: diferencias por pais/item, importancia temporal y valores extremos.
2:30 - 3:45	Modelo: regresion con HistGradientBoostingRegressor, GridSearchCV, MAE/RMSE/R2.
3:45 - 5:00	Demo: app Streamlit, prediccion de escenarios y mejoras futuras.

Idea central para cerrar: el proyecto no solo descarga datos, sino que convierte informacion publica en una herramienta predictiva util para tomar decisiones.