



Proyecto Final 4Geeks - FAOSTAT

Explicacion del proyecto, justificacion de la eleccion y desarrollo de las 7 fases de Machine Learning

Dataset publico + SQL + EDA +
modelo + app Streamlit

Este documento resume por que se eligio el proyecto, como cumple los requisitos de la entrega final y que se hizo en cada fase. La idea central es convertir datos abiertos de FAOSTAT en una herramienta predictiva para estimar valores de bioenergia por pais, periodo, producto y tipo de medicion.

Fecha del documento: 08/05/2026. Fuente principal: FAOSTAT, con el dominio AF como fuente solicitada y BE como base principal de modelado.

Por que elegimos este proyecto

Elegimos FAOSTAT porque es una fuente publica, internacional y realista. Sus datos no vienen preparados como un unico CSV de practica, sino repartidos en dominios tematicos, con codigos, paises, anos, unidades y medidas distintas. Eso hace que el proyecto se parezca mas a un caso profesional: hay que obtener datos, limpiarlos, unirlos, almacenarlos, analizarlos y convertirlos en predicciones utiles.

La bioenergia es un buen caso de negocio porque conecta produccion agroalimentaria, sostenibilidad, inversion e investigacion agricola. El modelo no se queda en una prediccion abstracta: ayuda a comparar escenarios por pais, producto y ano para detectar donde podria existir mayor potencial energetico.

Tambien fue una eleccion conveniente para la entrega porque permite cumplir los requisitos minimos: mas de 60.000 filas, mas de 20 predictores, variables categoricas, SQL, EDA completo, entrenamiento de modelo y despliegue con una app web.

Resumen del proyecto actual

Aspecto	Resultado
Problema ML	Regresion: estimar un valor numerico de bioenergia.
Fuente	FAOSTAT bulk downloads: AF, AE, CISP y BE.
Dataset final	101,995 filas y 29 columnas.
Periodo historico	Datos desde 1990 hasta 2023 (34 anos historicos).
Predictores	26 predictores: 19 numericos y 7 categoricos.
Modelo	HistGradientBoostingRegressor con preprocesamiento e imputacion.

Aspecto	Resultado
Metricas	MAE 60,528.02; RMSE 641,472.23; R2 log-target 0.990.
Despliegue	Aplicacion Streamlit preparada para Render mediante render.yaml.

Las 7 fases del proyecto

Estas fases explican tanto lo que pide 4Geeks como lo que ya existe en el proyecto actual.

Paso 1: Definicion del problema

Objetivo de la fase: Convertir una necesidad real en un problema de Machine Learning.

Como lo hicimos en este proyecto: Se definio una pregunta de negocio: que paises, productos y condiciones historicas muestran mayor potencial de produccion o uso de bioenergia dentro del sistema agroalimentario. En terminos tecnicos, se transformo en un problema de regresion para estimar `target_value`.

Valor que aporta: Da sentido al resto del trabajo: las variables, el modelo y la app existen para responder una necesidad concreta.

Paso 2: Obtencion y carga del conjunto de datos

Objetivo de la fase: Conseguir datos desde una fuente real y cargarlos en Python con Pandas.

Como lo hicimos en este proyecto: El script `src/data_download.py` descarga archivos ZIP oficiales desde el catalogo bulk de FAOSTAT. Despues lee los CSV internos, normaliza nombres de columnas y conserva el codigo de cada fuente.

Valor que aporta: Evita una entrega basada en un CSV artificial y demuestra una ingesta reproducible de datos publicos.

Paso 3: Almacenar la informacion

Objetivo de la fase: Guardar los datos en una base de datos y consultarlos con SQL.

Como lo hicimos en este proyecto: El script `src/database.py` crea una base SQLite en `data/database/faostat_project.db`. Se guardan tablas `raw_af`, `raw_ae`, `raw_be`, `raw_cisp` y `modeling_bioenergy`. Tambien se incluyen consultas `SELECT`, `JOIN`, agregaciones e `INSERT`.

Valor que aporta: Permite acceder a los datos de forma ordenada, reutilizable y mas segura que depender solo de archivos planos.

Paso 4: Analisis descriptivo

Objetivo de la fase: Conocer medidas estadísticas antes de modelar.

Como lo hicimos en este proyecto: El EDA calcula resumen de filas, columnas, nulos y estadísticas del objetivo. En el dataset final, la media del target es 447,212.72, la mediana 11,815.20, la desviación estándar 2,193,562.09 y la tasa media de nulos 19.26%.

Valor que aporta: Ayuda a detectar asimetría, valores extremos, nulos y patrones que influyen en el modelo.

Paso 5: EDA completo

Objetivo de la fase: Explorar relaciones, preparar variables y separar train/test.

Como lo hicimos en este proyecto: Se construyen variables categóricas, numéricas y temporales. También se crean lags del objetivo, media móvil y variables de contexto de investigación e inversión. La partición es temporal: entrenamiento con datos de 1990 a 2018 y test con datos de 2019 a 2023.

Valor que aporta: Reduce el riesgo de fuga temporal y mejora la lectura de qué variables son útiles para predecir.

Paso 6: Construcción y optimización del modelo

Objetivo de la fase: Entrenar un modelo adecuado y optimizar hiperparámetros.

Como lo hicimos en este proyecto: Se usa HistGradientBoostingRegressor porque funciona bien con datos tabulares y relaciones no lineales. Se optimiza con GridSearchCV. Los mejores parámetros fueron {'model__learning_rate': 0.08, 'model__max_iter': 140, 'model__max_leaf_nodes': 31}.

Valor que aporta: El modelo final alcanza un R2 de 0.990 sobre el objetivo logarítmico, lo que indica buena capacidad para aprender patrones históricos.

Paso 7: Despliegue del modelo

Objetivo de la fase: Crear una aplicación web para que el modelo pueda usarse fuera del notebook.

Como lo hicimos en este proyecto: La app src/app.py está hecha con Streamlit. Permite elegir país o región, año, ítem, elemento y unidad, ajustar variables de contexto y obtener una predicción usando models/bioenergy_model.joblib.

Valor que aporta: Convierte el modelo en una herramienta demostrable para usuarios, clientes o evaluadores.

Cumplimiento de requisitos

Requisito de la entrega	Evidencia en el proyecto	Estado
60.000 instancias mínimas	101,995 filas finales	Cumplido
20 variables predictoras mínimas	26 variables predictoras	Cumplido
Al menos 1 categórica	7 variables categóricas	Cumplido
Datos obtenidos de fuente real	FAOSTAT bulk downloads oficiales	Cumplido
CSV y Pandas	data/processed/modeling_dataset.csv	Cumplido
Base de datos y SQL	SQLite + SELECT/JOIN/INSERT	Cumplido
Modelo optimizado	GridSearchCV + métricas guardadas	Cumplido
App web	Streamlit + render.yaml	Cumplido

Guion corto para defenderlo

Momento	Mensaje
Inicio	El proyecto transforma datos públicos de FAOSTAT en una herramienta predictiva sobre bioenergía.
Datos	Usamos AF como fuente solicitada y enriquecimos con AE, CISP y BE para tener volumen y contexto.
Análisis	Exploramos distribuciones, nulos, variables temporales y diferencias por país, ítem y elemento.
Modelo	Entrenamos una regresión con HistGradientBoostingRegressor y optimización de hiperparámetros.
Cierre	La app Streamlit permite probar escenarios y convierte el trabajo técnico en una solución usable.

Sobre hacerlo en Canva

Si se necesita una version mas visual o editable para presentacion, este contenido se puede llevar a Canva y exportar de nuevo como PDF. Para la entrega tecnica, esta version generada con Python es mas reproducible porque se alimenta de metricas reales del proyecto y mantiene el logo oficial de 4Geeks.